



Universidade Federal do Pará
Instituto de Ciências Exatas e Naturais
Programa de Pós-Graduação em Computação
Linguagens Formais e Autômato
Teoria da Computação
Professor: Reginaldo Santos

Trabalho sobre Expressão Regular

1. [7,5 pontos] Em aplicações reais, informações textuais frequentemente encontram-se desestruturadas, contendo ruídos, inconsistências e múltiplos formatos de representação. Logs de sistemas, exportações de dados, mensagens e registros operacionais exigem mecanismos eficientes de identificação, extração e validação de padrões textuais.

As expressões regulares constituem uma ferramenta fundamental para reconhecer cadeias pertencentes a linguagens específicas, permitindo a identificação automática de padrões em grandes volumes de dados.

Neste contexto, desenvolva, na linguagem de programação de sua preferência, um sistema capaz de processar os arquivos disponibilizados e realizar as tarefas descritas a seguir, utilizando obrigatoriamente expressões regulares.

Arquivos de entrada (uso obrigatório):

01_atendimentos_bagunçados.txt
02_logs_mistos.log
03_mensagens_chat.txt
04_exportacao_suja.csv

- a) **Leitura e inspeção dos arquivos.** Implemente um módulo capaz de: ler todos os arquivos fornecidos; contabilizar o número de linhas de cada arquivo; identificar o tipo geral de conteúdo de cada arquivo (texto livre, log, chat ou CSV); apresentar uma pequena amostra de conteúdo de cada arquivo.
- b) **Extração de padrões com expressões regulares.** Implemente expressões regulares para identificar e extrair, no mínimo, os seguintes padrões: e-mails, telefones, CPFs, datas, horários, datas e horários combinados, URLs, valores monetários em reais, nomes próprios (definir critérios e justificar). Para cada tipo de padrão, o sistema deve: aplicar a expressão regular aos arquivos; extrair todas as ocorrências encontradas; indicar em qual arquivo ocorreram.



Universidade Federal do Pará
Instituto de Ciências Exatas e Naturais
Programa de Pós-Graduação em Computação
Linguagens Formais e Autômato
Teoria da Computação
Professor: Reginaldo Santos

- c) **Classificação entre cadeias válidas e inválidas.** Os arquivos contêm dados válidos e inválidos. O sistema deve ser capaz de classificá-los com base em critérios estruturais definidos por expressões regulares. Deve-se, no mínimo, classificar: e-mails válidos e inválidos; telefones válidos e inválidos; CPFs bem formatados e mal formatados; URLs válidas e inválidas; registros inconsistentes no arquivo CSV. Obs.: Não é necessário validar regras semânticas (por exemplo, dígitos verificadores de CPF), exceto se o grupo desejar implementar como diferencial.
- d) **Organização dos dados extraídos.** Os dados extraídos devem ser estruturados, como: dicionários, listas ou objetos; arquivos JSON ou CSV. Cada ocorrência deve conter, sempre que possível: tipo do dado; valor extraído; arquivo de origem; classificação (válido ou inválido).
- e) **Análise quantitativa.** O sistema deve produzir estatísticas sobre os dados extraídos, incluindo, no mínimo: quantidade total de ocorrências por tipo; quantidade de ocorrências válidas e inválidas por tipo; distribuição das ocorrências entre os arquivos.
2. [2,5 pontos] Elabore um relatório técnico, em formato de artigo SBC, descrevendo o desenvolvimento do trabalho. O relatório deve conter, mas não se limitar a:
- Abstract e Resumo
 - Introdução
 - Materiais e métodos
 - Descrição dos arquivos utilizados
 - Expressões regulares desenvolvidas e justificativas
 - Testes experimentais e análise dos resultados
 - Comentários finais

O relatório deve ter no mínimo 10 páginas (não contar o código-fonte).



Universidade Federal do Pará
Instituto de Ciências Exatas e Naturais
Programa de Pós-Graduação em Computação
Linguagens Formais e Autômato
Teoria da Computação
Professor: Reginaldo Santos

Instruções para a entrega do trabalho

O trabalho deve ser submetido via SIGAA antes da data limite, contendo:

- relatório técnico em formato PDF;
- código-fonte (como apêndice ou repositório);
- instruções de execução.

Não serão aceitos trabalhos após a data limite.

O uso de expressões regulares é obrigatório em todas as etapas relevantes do trabalho. O não uso ou uso superficial implicará redução significativa na nota.